

# Google Cardboard 的九轴融合算法—基于李群的扩展卡尔曼滤波

极品巧克力

2018-04-15

## 1 前言

九轴融合算法是指通过融合 IMU 中的加速度计（三轴）、陀螺仪（三轴）、磁场计（三轴），来获取物体姿态的方法。它是开发 VR 头显中的一个至关重要的部分。VR 头显必须要实时准确地获取用户头部的姿态，然后在屏幕上渲染出在对应的姿态所应该要看到的画面，才能让用户在 VR 世界里获得沉浸感。

因为人眼是非常精密的器官，如果渲染出来的画面稍微有一点点的延时或者偏差，人眼都能察觉出来，导致用户头晕想吐，再也不相信 VR 了。所以，VR 头显对九轴融合算法的实时性和精度提出了非常高的要求。

而另一方面，公开的九轴融合方法又少之又少，常见的就是互补滤波算法和 Madgwick 算法，但是这两个方法的精度都不能达到 VR 头显的要求。而精度高的九轴融合算法都掌握在一些算法公司手里，需要向他们支付高昂的算法使用费，源码的价格更是天价。



Cardboard 是谷歌在 2014 年发布的 VR 盒子,虽然它不是开源的,但是在 GitHub 上有很多 Cardboard 的反编译工程,比如<https://github.com/rsanchezsaez/cardboard-java>。Cardboard 的 VR 体验,可以在一定程度上,证明它的九轴融合算法是满足 VR 要求的。所以,我对 Cardboard 反编译工程中的九轴融合部分的程序进行了研读,这部分的程序大概有 5000 行左右。我在通读完程序之后,结合文献 [1],把程序背后的算法理论公式全部都反推出来,总结成了本文,与各位分享。

虽然早在 2014 年,Cardboard 就已经在 GitHub 上被反编译了,但是这么多年过去了,有关它的代码原理分析的文章却是几乎没有。能结合源代码,把它背后的算法理论基础详细推导出来的,本文应该算是第一篇。如有推导错误的地方,还请各位不吝赐教。

本文目标读者:传感器融合算法工程师。

## 2 预测

基于陀螺仪积分来预测出下一个姿态。

假设在  $k-1$  时刻的状态的  $SO3$  形式  $X_{k-1}$  的概率满足高斯分布，

$$\begin{aligned} X_{k-1} &= \mu_{k-1|k-1} \exp(\xi_{k-1|k-1}^\wedge) \quad \xi_{k-1|k-1} \sim N(m_{k-1|k-1} = 0, P_{k-1|k-1}) \\ \rho(X_{k-1}) &= a \exp\left(-\frac{1}{2} \left(\log\left((\mu_{k-1|k-1})^{-1} X_{k-1}\right)^\vee\right)^T (P_{k-1|k-1})^{-1} \log\left((\mu_{k-1|k-1})^{-1} X_{k-1}\right)^\vee\right) \\ &= a \exp\left(-\frac{1}{2} (\xi_{k-1|k-1} - 0)^T (P_{k-1|k-1})^{-1} (\xi_{k-1|k-1} - 0)\right) \end{aligned}$$

其中  $a$  为归一化常数。为方便起见，把满足上面条件的  $X_{k-1}$  表示成，  
 $X_{k-1} \sim N(\mu_{k-1|k-1}, P_{k-1|k-1})$ 。

在  $k-1$  时刻，陀螺仪的测量值为  $\omega_{k-1}$ ，如果没有噪声的话，则对下一个时刻  $k$  的状态均值的预测  $\mu_{k|k-1}$  为，

$$\mu_{k|k-1} = \mu_{k-1|k-1} \exp((\omega_{k-1} \Delta t_{k-1})^\wedge) \quad (1)$$

其中， $\Delta t_{k-1}$  为时刻  $k-1$  到时刻  $k$  的时间间隔， $\Delta t_{k-1} = t_k - t_{k-1}$ 。

而如果考虑噪声的影响的话，则对时刻  $k$  的预测的状态分布  $X_{k|k-1}$  要满足，

$$X_{k|k-1} = X_{k-1} \exp(((\omega_{k-1} + n_{k-1}) \Delta t_{k-1})^\wedge)$$

其中， $n_{k-1}$  表示陀螺仪数据的噪声，协方差  $R_{k-1}$  可以通过采集一段时间的数据  $n_{k-1}$ ，计算得到  $R_{k-1} = E(n_{k-1} (n_{k-1})^T)$ 。

所以，新的均值  $\mu_{k|k-1}$  附近的扰动  $\xi_{k|k-1}$  要满足这样的分布，

$$\begin{aligned} \exp(\xi_{k|k-1}^\wedge) &= \exp((- \omega_{k-1} \Delta t_{k-1})^\wedge) \exp(\xi_{k-1|k-1}^\wedge) \exp(((\omega_{k-1} + n_{k-1}) \Delta t_{k-1})^\wedge) \\ &= \exp\left(\left(\exp((- \omega_{k-1} \Delta t_{k-1})^\wedge) \xi_{k-1|k-1}\right)^\wedge\right) \exp((- \omega_{k-1} \Delta t_{k-1})^\wedge) \exp(((\omega_{k-1} + n_{k-1}) \Delta t_{k-1})^\wedge) \\ &\approx \exp\left(\left(\exp((- \omega_{k-1} \Delta t_{k-1})^\wedge) \xi_{k-1|k-1}\right)^\wedge\right) \exp\left(\left(- \omega_{k-1} \Delta t_{k-1} + J_r (- \omega_{k-1} \Delta t_{k-1})^{-1} (\omega_{k-1} + n_{k-1}) \Delta t_{k-1}\right)^\wedge\right) \\ &= \exp\left(\left(\exp((- \omega_{k-1} \Delta t_{k-1})^\wedge) \xi_{k-1|k-1}\right)^\wedge\right) \exp\left(\left(- \omega_{k-1} \Delta t_{k-1} + J_r (\omega_{k-1} \Delta t_{k-1}) \omega_{k-1} \Delta t_{k-1}\right)^\wedge\right) \\ &\approx \exp\left(\left(\exp((- \omega_{k-1} \Delta t_{k-1})^\wedge) \xi_{k-1|k-1}\right)^\wedge\right) \exp\left(\left(J_r (\omega_{k-1} \Delta t_{k-1}) n_{k-1} \Delta t_{k-1}\right)^\wedge\right) \\ &\approx \exp\left(\left(\exp((- \omega_{k-1} \Delta t_{k-1})^\wedge) \xi_{k-1|k-1} + J_r (\omega_{k-1} \Delta t_{k-1}) n_{k-1} \Delta t_{k-1}\right)^\wedge\right) \\ &\approx \exp\left(\left(\exp((- \omega_{k-1} \Delta t_{k-1})^\wedge) \xi_{k-1|k-1} + n_{k-1} \Delta t_{k-1}\right)^\wedge\right) \end{aligned}$$

又因为有  $SO3$  上的性质,  $\exp(\phi^\wedge)^{-1} = \exp((- \phi)^\wedge)$ , 所以, 上式中的  $\exp((\omega_{k-1} \Delta t_{k-1})^\wedge)^{-1} = \exp((- \omega_{k-1} \Delta t_{k-1})^\wedge)$ 。所以, 原式可以转换如下,

$$\exp(\xi_{k|k-1}^\wedge) = \exp((- \omega_{k-1} \Delta t_{k-1})^\wedge) \exp(\xi_{k-1|k-1}^\wedge) \exp(((\omega_{k-1} + n_{k-1}) \Delta t_{k-1})^\wedge)$$

这时候, 又因为  $SO3$  上的伴随性质,

$$\begin{aligned} R \exp(p^\wedge) R^T &= \exp((Rp)^\wedge) \Rightarrow \\ R \exp(p^\wedge) &= \exp((Rp)^\wedge) R \end{aligned}$$

原式就可以转换为,

$$\begin{aligned} \exp(\xi_{k|k-1}^\wedge) &= \exp((- \omega_{k-1} \Delta t_{k-1})^\wedge) \exp(\xi_{k-1|k-1}^\wedge) \exp(((\omega_{k-1} + n_{k-1}) \Delta t_{k-1})^\wedge) \\ &= \exp\left(\left(\exp((- \omega_{k-1} \Delta t_{k-1})^\wedge) \xi_{k-1|k-1}\right)^\wedge\right) \exp((- \omega_{k-1} \Delta t_{k-1})^\wedge) \exp(((\omega_{k-1} + n_{k-1}) \Delta t_{k-1})^\wedge) \\ &\approx \exp\left(\left(\exp((- \omega_{k-1} \Delta t_{k-1})^\wedge) \xi_{k-1|k-1}\right)^\wedge\right) \exp\left(\left(- \omega_{k-1} \Delta t_{k-1} + J_r(- \omega_{k-1} \Delta t_{k-1})^{-1}(\omega_{k-1} + n_{k-1}) \Delta t_{k-1}\right)^\wedge\right) \\ &= \exp\left(\left(\exp((- \omega_{k-1} \Delta t_{k-1})^\wedge) \xi_{k-1|k-1}\right)^\wedge\right) \exp((- \omega_{k-1} \Delta t_{k-1} + J_r(\omega_{k-1} \Delta t_{k-1}) \omega_{k-1} \Delta t_{k-1})^\wedge) \\ &\approx \exp\left(\left(\exp((- \omega_{k-1} \Delta t_{k-1})^\wedge) \xi_{k-1|k-1}\right)^\wedge\right) \exp((J_r(\omega_{k-1} \Delta t_{k-1}) n_{k-1} \Delta t_{k-1})^\wedge) \\ &\approx \exp\left(\left(\exp((- \omega_{k-1} \Delta t_{k-1})^\wedge) \xi_{k-1|k-1} + J_r(\omega_{k-1} \Delta t_{k-1}) n_{k-1} \Delta t_{k-1}\right)^\wedge\right) \\ &\approx \exp\left(\left(\exp((- \omega_{k-1} \Delta t_{k-1})^\wedge) \xi_{k-1|k-1} + n_{k-1} \Delta t_{k-1}\right)^\wedge\right) \end{aligned}$$

所以, 就可以得到,

$$\xi_{k|k-1} = \exp((- \omega_{k-1} \Delta t_{k-1})^\wedge) \xi_{k-1|k-1} + n_{k-1} \Delta t_{k-1}$$

所以, 新的扰动  $\xi_{k|k-1}^\wedge$  的均值  $m_{k|k-1}$ ,

$$\begin{aligned} m_{k|k-1} &= E(\xi_{k|k-1}) \\ &= E\left(\exp((- \omega_{k-1} \Delta t_{k-1})^\wedge) \xi_{k-1|k-1} + n_{k-1} \Delta t_{k-1}\right) \\ &= \exp((- \omega_{k-1} \Delta t_{k-1})^\wedge) E(\xi_{k-1|k-1}) \\ &= 0 \end{aligned}$$

新的扰动  $\xi_{k|k-1}^\wedge$  的协方差,  $P_{k|k-1}$ ,

$$\begin{aligned}
P_{k|k-1} &= E \left( (\xi_{k|k-1} - m_{k|k-1}) (\xi_{k|k-1} - m_{k|k-1})^T \right) \\
&= E \left( \xi_{k|k-1} (\xi_{k|k-1})^T \right) \\
&= E \left( (\exp((- \omega_{k-1} \Delta t_{k-1})^\wedge) \xi_{k-1|k-1} + n_{k-1} \Delta t_{k-1}) (\exp((- \omega_{k-1} \Delta t_{k-1})^\wedge) \xi_{k-1|k-1} + n_{k-1} \Delta t_{k-1})^T \right) \\
&= E \left( \exp((- \omega_{k-1} \Delta t_{k-1})^\wedge) \xi_{k-1|k-1} (\xi_{k-1|k-1})^T \exp((- \omega_{k-1} \Delta t_{k-1})^\wedge)^T \right) \\
&\quad + E \left( \exp((- \omega_{k-1} \Delta t_{k-1})^\wedge) \xi_{k-1|k-1} (n_{k-1})^T \Delta t_{k-1} \right) \\
&\quad + E \left( n_{k-1} \Delta t_{k-1} (\xi_{k-1|k-1})^T \exp((- \omega_{k-1} \Delta t_{k-1})^\wedge)^T \right) \\
&\quad + E \left( n_{k-1} \Delta t_{k-1} (n_{k-1})^T \Delta t_{k-1} \right) \\
&= \exp((- \omega_{k-1} \Delta t_{k-1})^\wedge) E \left( \xi_{k-1|k-1} (\xi_{k-1|k-1})^T \right) \exp((- \omega_{k-1} \Delta t_{k-1})^\wedge)^T \\
&\quad + \exp((- \omega_{k-1} \Delta t_{k-1})^\wedge) E \left( \xi_{k-1|k-1} (n_{k-1})^T \right) \Delta t_{k-1} \\
&\quad + \Delta t_{k-1} E \left( n_{k-1} (\xi_{k-1|k-1})^T \right) \exp((- \omega_{k-1} \Delta t_{k-1})^\wedge)^T \\
&\quad + \Delta t_{k-1} E \left( n_{k-1} (n_{k-1})^T \right) \Delta t_{k-1} \\
&= \exp((- \omega_{k-1} \Delta t_{k-1})^\wedge) E \left( \xi_{k-1|k-1} (\xi_{k-1|k-1})^T \right) \exp((- \omega_{k-1} \Delta t_{k-1})^\wedge)^T + \Delta t_{k-1} E \left( n_{k-1} (n_{k-1})^T \right) \\
&= \exp((- \omega_{k-1} \Delta t_{k-1})^\wedge) P_{k-1|k-1} \exp((- \omega_{k-1} \Delta t_{k-1})^\wedge)^T + \Delta t_{k-1} R_{k-1} \Delta t_{k-1}
\end{aligned}$$

所以,

$$P_{k|k-1} = \exp((- \omega_{k-1} \Delta t_{k-1})^\wedge) P_{k-1|k-1} \exp((- \omega_{k-1} \Delta t_{k-1})^\wedge)^T + \Delta t_{k-1} R_{k-1} \Delta t_{k-1} \quad (2)$$

所以, 最终得到,

$$X_{k|k-1} = \mu_{k|k-1} \exp(\xi_{k|k-1}^\wedge) \sim N(\mu_{k|k-1}, P_{k|k-1}) \quad \xi_{k|k-1} \sim N(0, P_{k|k-1})$$

### 3 更新

设在世界坐标系下，加速度计所测的重力向量为  $g_w$ ，磁场计所测的磁场向量为  $\gamma_w$ 。则在时刻  $k$  时，加速度计所测的重力向量为  $g_k$ ，磁场计所测的磁场向量为  $\gamma_k$ 。加速度计上面的测量噪声  $n_{g_k}$  满足  $n_{g_k} \sim N(0, Q_{g_k})$ 。磁场计上面的测量噪声  $n_{\gamma_k}$  满足  $n_{\gamma_k} \sim N(0, Q_{\gamma_k})$ 。

#### 3.1 加速度计测量更新

把第一部分预测出来的姿态  $\mu_{k|k-1}$ ，作为预测的测量姿态，可以预测出当前加速度计的测量值  $g_{k|k-1}$ ，其计算过程如下，

$$\begin{aligned} g_w &= \mu_{k|k-1} g_{k|k-1} \Rightarrow \\ g_{k|k-1} &= (\mu_{k|k-1})^{-1} g_w \\ &= (\mu_{k|k-1})^T g_w \end{aligned}$$

而根据实际测量值  $g_k$ ，可以反过来计算出姿态  $\mu_{g_k}$ ，作为实际的测量姿态。以之前的预测姿态  $\mu_{k|k-1}$  为初值，则把两者的关系表示为，

$$\mu_{g_k} = \mu_{k|k-1} \exp \left( (\xi_{g_{k|k-1}, g_k})^\wedge \right)$$

可以把  $\xi_{g_{k|k-1}, g_k}$  优化出来，或者直接叉乘出来。

$$\begin{aligned} g_w &= \mu_{g_k} g_k \Rightarrow \\ g_w &= \mu_{k|k-1} \exp \left( (\xi_{g_{k|k-1}, g_k})^\wedge \right) g_k \\ (\mu_{k|k-1})^{-1} g_w &= \exp \left( (\xi_{g_{k|k-1}, g_k})^\wedge \right) g_k \Rightarrow \\ g_{k|k-1} &= \exp \left( (\xi_{g_{k|k-1}, g_k})^\wedge \right) g_k \end{aligned}$$

根据李代数与向量叉乘的转换关系。不考虑测量噪声  $n_{g_k}$ ，则可以得到  $\xi_{g_{k|k-1}, g_k}$  的均值  $m_{g_{k|k-1}, g_k} \circ$

$$\begin{aligned}
c &= \frac{g_k}{\|g_k\|} \times \frac{g_{k|k-1}}{\|g_{k|k-1}\|} \\
\|c\| &= \left\| \frac{g_k}{\|g_k\|} \right\| \cdot \left\| \frac{g_{k|k-1}}{\|g_{k|k-1}\|} \right\| \sin \theta = \sin \theta \Rightarrow \\
\theta &= \arcsin(\|c\|) = \arcsin\left(\frac{g_k}{\|g_k\|} \times \frac{g_{k|k-1}}{\|g_{k|k-1}\|}\right) \Rightarrow \\
m_{g_{k|k-1}, g_k} &= \frac{c}{\|c\|} \theta \\
&= \left( \frac{g_k}{\|g_k\|} \times \frac{g_{k|k-1}}{\|g_{k|k-1}\|} \right) \frac{1}{\left\| \frac{g_k}{\|g_k\|} \right\| \cdot \left\| \frac{g_{k|k-1}}{\|g_{k|k-1}\|} \right\|} \arcsin\left(\left\| \frac{g_k}{\|g_k\|} \right\| \cdot \left\| \frac{g_{k|k-1}}{\|g_{k|k-1}\|} \right\|\right)
\end{aligned}$$

设  $\xi_{g_{k|k-1}, g_k}$  上的噪声为  $n_\xi$ , 则关系满足如下,

$$\xi_{g_{k|k-1}, g_k} = m_{g_{k|k-1}, g_k} + n_\xi$$

进一步得到,

$$\begin{aligned}
\xi_{g_{k|k-1}, g_k} &= m_{g_{k|k-1}, g_k} + n_\xi \\
&= \left( \frac{g_k + n_{g_k}}{\|g_k + n_{g_k}\|} \times \frac{g_{k|k-1}}{\|g_{k|k-1}\|} \right) \frac{1}{\left\| \frac{g_k + n_{g_k}}{\|g_k + n_{g_k}\|} \right\| \cdot \left\| \frac{g_{k|k-1}}{\|g_{k|k-1}\|} \right\|} \arcsin\left(\left\| \frac{g_k + n_{g_k}}{\|g_k + n_{g_k}\|} \right\| \cdot \left\| \frac{g_{k|k-1}}{\|g_{k|k-1}\|} \right\|\right)
\end{aligned}$$

要获得  $n_\xi$  与之  $n_{g_k}$  间的关系,

$$\begin{aligned}
n_\xi &= f(n_{g_k}) \\
&= \left( \frac{g_k + n_{g_k}}{\|g_k + n_{g_k}\|} \times \frac{g_{k|k-1}}{\|g_{k|k-1}\|} \right) \frac{1}{\left\| \frac{g_k + n_{g_k}}{\|g_k + n_{g_k}\|} \right\| \cdot \left\| \frac{g_{k|k-1}}{\|g_{k|k-1}\|} \right\|} \arcsin\left(\left\| \frac{g_k + n_{g_k}}{\|g_k + n_{g_k}\|} \right\| \cdot \left\| \frac{g_{k|k-1}}{\|g_{k|k-1}\|} \right\|\right) - m_{g_{k|k-1}, g_k}
\end{aligned}$$

这两者间的关系不是线性化的, 那么就只能进行线性化, 一阶泰勒展开,

$$\begin{aligned}
n_\xi &= f(n_{g_k})|_{n_{g_k} \rightarrow 0} + \frac{\partial f(n_{g_k})}{\partial n_{g_k}} \Big|_{n_{g_k} \rightarrow 0} n_{g_k} \\
&= \frac{\partial f(n_{g_k})}{\partial n_{g_k}} \Big|_{n_{g_k} \rightarrow 0} n_{g_k} \\
&= F_{n_{g_k}} n_{g_k}
\end{aligned}$$

其中,  $F_{n_{g_k}} = \frac{\partial f(n_{g_k})}{\partial n_{g_k}} \Big|_{n_{g_k} \rightarrow 0}$  的计算, 采用数值扰动的方法。

从而, 可以得到  $Q_{g_k|k-1, g_k} \circ$

$$Q_{g_k|k-1, g_k} = E \left( (\xi_{g_k|k-1, g_k} - m_{g_k|k-1, g_k}) (\xi_{g_k|k-1, g_k} - m_{g_k|k-1, g_k})^T \right) = E (n_\xi n_\xi^T)$$

最终得到,  $\xi_{g_k|k-1, g_k}$  的分布,

$$\xi_{g_k|k-1, g_k} \sim N(m_{g_k|k-1, g_k}, Q_{g_k|k-1, g_k})$$

再进行转换, 用跟第一部分同样的方法, 转换出扰动  $\xi_{Z_k} \circ$

$$\begin{aligned}
Z_k &= \mu_{k|k-1} \exp \left( \xi_{g_k|k-1, g_k}^\wedge \right) \\
&= \mu_{k|k-1} \exp \left( m_{g_k|k-1, g_k}^\wedge \right) \exp \left( \xi_{Z_k}^\wedge \right) \\
\xi_{Z_k} &\sim N(0, Q_k)
\end{aligned}$$

用  $z_k$  来表示。

$$\begin{aligned}
z_k &= \mu_{k|k-1} \exp \left( m_{g_k|k-1, g_k}^\wedge \right) \\
Z_k &= z_k \exp \left( \xi_{z_k}^\wedge \right) \sim N(z_k, Q_k)
\end{aligned}$$

所以, 根据第一部分, 可以得到  $\mu_{k|k-1}$ , 现在又得到了  $z_k$ 。综合这两者的信息, 可以得到,  $\rho(\mu_k | \mu_{k|k-1}, z_k)$ 。就是要求一个  $\mu_k$ , 使得  $\rho(\mu_k | \mu_{k|k-1}, z_k)$  最大, 用公式表达如下。



$$\begin{aligned}
\hat{\mu}_k &= \arg \max_{\mu_k} \rho(\mu_k | \mu_{k|k-1}, z_k) \\
&= \arg \max_{\mu_k} \frac{\rho(\mu_k | \mu_{k|k-1}) \rho(z_k | \mu_{k|k-1})}{\rho(z_k | \mu_{k|k-1})} \\
&= \arg \max_{\mu_k} \rho(\mu_k | \mu_{k|k-1}) \rho(z_k | \mu_k) \\
&= \arg \max_{\mu_k} \exp \left( -\frac{1}{2} \left( \left( \log(\mu_{k|k-1}^{-1} \mu_k)^\vee \right)^T P_{k|k-1}^{-1} \log(\mu_{k|k-1}^{-1} \mu_k)^\vee \right) \right) \exp \left( -\frac{1}{2} \left( \left( \log(\mu_k^{-1} z_k)^\vee \right)^T Q_k^{-1} \log(\mu_k^{-1} z_k)^\vee \right) \right)
\end{aligned}$$

其中,  $\mu_k$  是个未知数, 用  $\mu_k = \mu_{k|k-1} \exp(\xi^\wedge)$ , 转换成用未知数  $\xi$  来表示。然后, 上式就可以转换为,

$$\begin{aligned}
\hat{\mu}_k &= \exp \left( -\frac{1}{2} \left( \left( \log(\mu_{k|k-1}^{-1} (\mu_{k|k-1} \exp(\xi^\wedge)))^\vee \right)^T P_{k|k-1}^{-1} \log(\mu_{k|k-1}^{-1} (\mu_{k|k-1} \exp(\xi^\wedge)))^\vee \right) \right) \\
&\quad \exp \left( -\frac{1}{2} \left( \left( \log((\mu_{k|k-1} \exp(\xi^\wedge))^{-1} z_k)^\vee \right)^T Q_k^{-1} \log((\mu_{k|k-1} \exp(\xi^\wedge))^{-1} z_k)^\vee \right) \right) \\
&= \exp \left( -\frac{1}{2} ((\xi - 0)^T P_{k|k-1}^{-1} (\xi - 0)) \right) \exp \left( -\frac{1}{2} \left( \left( \log((\mu_{k|k-1} \exp(\xi^\wedge))^{-1} z_k)^\vee \right)^T Q_k^{-1} \log((\mu_{k|k-1} \exp(\xi^\wedge))^{-1} z_k)^\vee \right) \right)
\end{aligned}$$

但这样子也解不出来。对上式中的部分, 在  $\xi = 0$  处进行线性化, 一阶泰勒展开。则可以转换为,

$$\begin{aligned}
a(\xi) &= \xi - 0 = \xi \\
b(\xi) &= \log \left( (\mu_{k|k-1} \exp(\xi^\wedge))^{-1} z_k \right)^\vee \\
J &= \left. \frac{\partial b(\xi)}{\partial \xi} \right|_{\xi \rightarrow 0} \\
&= \left. \frac{\partial \log \left( (\mu_{k|k-1} \exp(\xi^\wedge))^{-1} \exp(m_{g_{k|k-1}, g_k}^\wedge) \right)^\vee}{\partial \xi} \right|_{\xi \rightarrow 0} \\
&= \left. \frac{\partial \log(\exp(\xi^\wedge) z_k)^\vee}{\partial \xi} \right|_{\xi \rightarrow 0} \\
b(\xi) &= b(0) + J(\xi - 0) \\
&= m_{z_k} + J\xi
\end{aligned}$$

其中,  $J$  的计算, 程序里面是用数值扰动的方法。这里应该也可以用解析的方法, 把公式都展开来推导。

接下来, 为了转换成卡尔曼滤波的形式, 用  $H = -J$  来表示。  
所以, 原式就可以表示为,

$$\begin{aligned} & \rho(\mu_k | \mu_{k|k-1}, z_k) \\ & \propto \exp\left(-\frac{1}{2} \left((\xi - 0)^T P_{k|k-1}^{-1} (\xi - 0)\right)\right) \exp\left(-\frac{1}{2} \left((m_{z_k} - H\xi)^T Q_k^{-1} (m_{z_k} - H\xi)\right)\right) \end{aligned}$$

参考《State Estimation for Robotics》的第 3.1.2 和 3.3.2 节, 求  $\arg \max_{\mu_k} \rho(\mu_k | \mu_{k|k-1}, z_k)$ ,  
则上式最终可以转换出卡尔曼滤波的形式了。

$$\begin{cases} K_k = P_{k|k-1} H_k^T (H_k P_{k|k-1} H_k^T + Q_k)^{-1} \\ m_{k|k}^- = 0 + K_k (m_{z_k} - 0) \\ P_{k|k}^- = (I - K_k H_k) P_{k|k-1} \end{cases} \quad (3)$$

所以,

$$\xi_{k|k}^- \sim N(m_{k|k}^-, P_{k|k-1}^-)$$

同时,

$$P_{k|k-1}^- = E\left(\left(\xi_{k|k}^- - m_{k|k}^-\right)\left(\xi_{k|k}^- - m_{k|k}^-\right)^T\right)$$

则融合后的姿态的均值  $\mu_{k|k}$  为,

$$\mu_{k|k} = \mu_{k|k-1} \exp\left(\left(m_{k|k}^-\right)^\wedge\right) \quad (4)$$

设相对于姿态  $\mu_{k|k}$  的李代数扰动。则  $\xi_{k|k}$  与  $\xi_{k|k}^-$  的关系要满足,

$$\begin{aligned}
\mu_{k|k} \exp \left( \left( \xi_{k|k} \right)^\wedge \right) &= \mu_{k|k-1} \exp \left( \left( \xi_{k|k}^- \right)^\wedge \right) \Rightarrow \\
\xi_{k|k} &= \log \left( \mu_{k|k}^{-1} \mu_{k|k-1} \exp \left( \left( \xi_{k|k}^- \right)^\wedge \right) \right)^\vee \\
&= \log \left( \left( \mu_{k|k-1} \exp \left( \left( m_{k|k}^- \right)^\wedge \right) \right)^{-1} \mu_{k|k-1} \exp \left( \left( \xi_{k|k}^- \right)^\wedge \right) \right)^\vee \\
&= \log \left( \left( \exp \left( \left( m_{k|k}^- \right)^\wedge \right) \right)^{-1} \mu_{k|k-1}^{-1} \mu_{k|k-1} \exp \left( \left( \xi_{k|k}^- \right)^\wedge \right) \right)^\vee \\
&= \log \left( \exp \left( \left( -m_{k|k}^- \right)^\wedge \right) \exp \left( \left( \xi_{k|k}^- \right)^\wedge \right) \right)^\vee \\
&= \log \left( \exp \left( \left( -m_{k|k}^- + J_r \left( -m_{k|k}^- \right)^{-1} \xi_{k|k}^- \right)^\wedge \right) \right)^\vee \\
&= -m_{k|k}^- + J_r \left( m_{k|k}^- \right) \xi_{k|k}^-
\end{aligned}$$

所以, 得到扰动  $\xi_{k|k}$  的均值  $m_{k|k}$ ,

$$\begin{aligned}
m_{k|k} &= E \left( \xi_{k|k} \right) \\
&= E \left( -m_{k|k}^- + J_r \left( m_{k|k}^- \right) \xi_{k|k}^- \right) \\
&= -m_{k|k}^- + J_r \left( m_{k|k}^- \right) E \left( \xi_{k|k}^- \right) \\
&= J_r \left( m_{k|k}^- \right) m_{k|k}^- - m_{k|k}^- \\
&\approx 0
\end{aligned}$$

得到扰动  $\xi_{k|k}$  的协方差  $P_{k|k}$ ,

$$\begin{aligned}
P_{k|k} &= E \left( \left( \xi_{k|k} - \left( J_r \left( m_{k|k}^- \right) m_{k|k}^- - m_{k|k}^- \right) \right) \left( \xi_{k|k} - \left( J_r \left( m_{k|k}^- \right) m_{k|k}^- - m_{k|k}^- \right) \right)^T \right) \\
&= E \left( \left( -m_{k|k}^- + J_r \left( m_{k|k}^- \right) \xi_{k|k}^- - \left( J_r \left( m_{k|k}^- \right) m_{k|k}^- - m_{k|k}^- \right) \right) \left( -m_{k|k}^- + J_r \left( m_{k|k}^- \right) \xi_{k|k}^- - \left( J_r \left( m_{k|k}^- \right) m_{k|k}^- - m_{k|k}^- \right) \right)^T \right) \\
&= E \left( \left( J_r \left( m_{k|k}^- \right) \xi_{k|k}^- - J_r \left( m_{k|k}^- \right) m_{k|k}^- \right) \left( J_r \left( m_{k|k}^- \right) \xi_{k|k}^- - J_r \left( m_{k|k}^- \right) m_{k|k}^- \right)^T \right) \\
&= J_r \left( m_{k|k}^- \right) E \left( \left( \xi_{k|k}^- - m_{k|k}^- \right) \left( \xi_{k|k}^- - m_{k|k}^- \right)^T \right) J_r \left( m_{k|k}^- \right)^T \\
&= J_r \left( m_{k|k}^- \right) P_{k|k-1}^- J_r \left( m_{k|k}^- \right)^T
\end{aligned}$$

所以,

$$P_{k|k} = J_r \left( m_{k|k}^- \right) P_{k|k-1}^- J_r \left( m_{k|k}^- \right)^T \quad (5)$$

所以,  $X_k$  的分布满足,

$$\begin{aligned} X_k &= \mu_{k|k-1} \exp \left( \xi_{k|k} \right) \sim N \left( \mu_{k|k-1}, P_{k|k} \right) \\ \xi_{k|k} &\sim N \left( 0, P_{k|k} \right) \end{aligned}$$

### 3.2 公式总结

前面推导的公式总结出来就是,

<b>A. Time Update(“Predict”)</b>	
(1) Project the state ahead, eq.(1)	
$\mu_{k k-1} = \mu_{k-1 k-1} \exp \left( (\omega_{k-1} \Delta t_{k-1})^\wedge \right)$	
(2) Project the error covariance ahead, eq.(2)	
$P_{k k-1} = \exp \left( (\omega_{k-1} \Delta t_{k-1})^\wedge \right) P_{k-1 k-1} \exp \left( (\omega_{k-1} \Delta t_{k-1})^\wedge \right)^T + \Delta t_{k-1} R_{k-1} \Delta t_{k-1}$	
<b>B. Measurement Update(“Correct”)</b>	
(1) Compute the Kalman gain, eq.(3)	
$K_k = P_{k k-1} H_k^T \left( H_k P_{k k-1} H_k^T + Q \right)^{-1}$	
(2) Update estimate with measurement $z_k$ , eq.(3)	
$m_{k k}^- = 0 + K_k (m_{z_k} - 0)$	
(3) Update the error covariance, eq.(3)	
$P_{k k}^- = (I - K_k H_k) P_{k k-1}$	
(4) Project the state ahead with $m_k$ , eq.(4)	
$\mu_{k k} = \mu_{k k-1} \exp \left( \left( m_{k k}^- \right)^\wedge \right)$	
(5) Project the error covariance ahead with $m_k$ , eq.(5)	
$P_{k k} = J_r \left( m_{k k}^- \right) P_{k k-1}^- J_r \left( m_{k k}^- \right)^T$	

其中符号含义如下，

- $\mu_{k|k-1}$ ，预测姿态。
- $\mu_{k|k}$ ，校正姿态。
- $\omega$ ，角速度。对 ESKF 系统来说，这是控制输入，或称为驱动输入。
- $\exp((\omega_{k-1}\Delta t_{k-1})^\wedge)$ ，用驱动角度向量  $\omega\Delta t$  计算得到的旋转矩阵。也可以用四元数表示。
- $P_{k|k-1}$ ，先验估计误差协方差。
- $P_{k|k}$ ，后验估计误差协方差。
- $R$ ，测量噪声协方差。
- $Q$ ，过程噪声协方差。
- $K$ ，卡尔曼增益。
- $f()$ ，Process nonlinear vector function
- $h()$ ，Observation nonlinear vector function
- $H$ ，是  $h()$  相对于状态向量  $m$  的偏导数的 Jacobian 矩阵。
- $m_{k|k}^-$ ，状态向量。在 ESKF 系统中，是表示旋转误差的旋转向量。每次迭代都重置为 0。
- $z_k$ ，测量向量。
- $m_{z_k}$ ，创新向量，或称为残差向量。
- $\exp\left(\left(m_{k|k}^-\right)^\wedge\right)$ ，用误差旋转向量  $m_{k|k}^-$  计算得到的旋转矩阵。也可以用四元数表示。
- $F$ ，是  $f()$  相对于状态向量  $m$  的偏导数的 Jacobian 矩阵。
  - 对于驱动角度向量  $\omega\Delta t$ ， $F = \exp((\omega_{k-1}\Delta t_{k-1})^\wedge)$ 。参见公式 (2)。
  - 对于误差旋转向量  $m_{k|k}^-$ ， $F = J_r(m_{k|k}^-)$ 。参见公式 (5)。

上面的方法跟《State Estimation for Robotics》的第 7.3.4 和 8.2.4 节很像，但是上面的方法，对协方差的处理更加精细。

要融合磁场计，也是同样的方法。


要融合视觉 SLAM 中送过来的姿态，也是同样的方法。

## 4 实际程序

在 cardboard 的实际程序中，还有很多细节的处理。比如：

- 增加了很多加权滤波的方法。
- 把加速度计的模的变化滤波出来，实时更新加速度计的协方差。这一步，相当于是 madgwick 里面的动态调整权重，但这一步更好，因为直接算加速度计的协方差来调整权重，而不是通过陀螺仪的测量值来间接表示运动过快而调整权重。
- 在静止的时候，把陀螺仪的偏移滤波出来。
- 还有时间差平滑滤波的方法。

在融合磁场计的时候，把磁场计向量映射到水平面上，相当于只优化水平面上的旋转偏差。这个，在空间想象时，应该保持重力竖直方向  $(0, 0, 1)$  不变，以此作为参考，再看原来的模型，就容易理解了。



但是没有对磁场计进行修正。如果要对磁场计进行修正，简单的方法可以参考 madgwick 里面的方法。全面的方法，则要参考那些专门搞磁场计标定的论文了。

## 5 总结

Cardboard 里面的九轴融合算法，效果比 Madgwick 方法和互补滤波方法都要好，对细节的处理也非常棒。以后再写一篇文章，详细比较基于李群的扩展卡尔曼滤波方法，Madgwick 算法，互补滤波的异同。

根据参考文献 [1]，这套理论也同样可以使用在六自由度（位移 + 旋转）融合上面，只需要把  $SO3$  改成  $SE3$  就可以了。可以用同一套理论，把视觉 SLAM 的位姿与 IMU 位姿融合在一起，得到融合后的六自由度数据，应用在 VR 头显中。

希望有一天，VR 头显的体验能做到像电影《头号玩家》里面那样。与仍然还在做 VR 的各位同行共勉。



## 6 求赞赏

您觉得，本文值多少？



## 7 有奖问答

给各位出一道思考题。

已知，一个 IMU 水平地放在桌面上不动。重力大小为  $g$ 。陀螺仪和加速度计以相同的频率同时输出，输出的时间间隔为  $\Delta t$ 。它的初始状态为  $x_0$ 。陀螺仪数据的噪声为  $n_\omega$ ，加速度计数据的噪声为  $n_a$ 。

$$x_0 \in so(3) \sim N(0, P_0)$$

$$n_\omega \in R^3 \sim N(0, Q)$$

$$n_a \in R^3 \sim N(0, R)$$

其中， $P_0$ ， $Q$ ， $R$  都为对角矩阵。则随着时间的增长，请问，

- (1) 这个 IMU 的后验状态协方差是否会收敛？
- (2) 如果收敛的话，会收敛到什么值？



## 8 参考文献

1. Bourmaud G, Megret R, Giremus A, et al. Discrete Extended Kalman Filter on Lie groups[C]// Signal Processing Conference. EURASIP, 2013:1-5.
2. Timothy D. Barfoot. State Estimation for Robotics [M].Cambridge University Press, 2017.